



# 基于深度神经网络的个性化推荐系统研究\*

字云飞, 李业丽, 孙华艳

(北京印刷学院 信息工程学院, 北京 102600)

**摘要:** 深度神经网络由于结构类似于生物神经网络, 因此拥有高效、精准抽取信息深层隐含特征的能力和能够学习多层的抽象特征表示, 且能够对跨域、多源、异质的内容信息进行学习等优势。提出了一种基于多用户-项目结合深度神经网络抽取特征、自学习等优势实现信息个性化推荐的模型, 该模型通过对输入多源异构数据特征进行深度神经网络学习、抽取, 再融合协同过滤中的广泛个性化产生候选集, 然后通过二次模型学习产生排序集, 实现精准、实时、个性化推荐。通过真实数据集对模型评估实验, 实验结果表明, 该模型能够很好地学习、抽取用户隐特征, 并且能够一定程度上解决传统推荐系统稀疏性、新物品等问题, 同时实现了更加精准、实时、个性化的推荐。

**关键词:** 深度神经网络; 个性化推荐; 候选集; 排序集; 多视角

**中图分类号:** TN311

**文献标识码:** A

**DOI:** 10.16157/j.issn.0258-7998.181396

**中文引用格式:** 字云飞, 李业丽, 孙华艳. 基于深度神经网络的个性化推荐系统研究[J]. 电子技术应用, 2019, 45(1): 14-18, 22.

**英文引用格式:** Zi Yunfei, Li Yeli, Sun Huayan. Research of personalized recommendation system based on deep neural network[J]. Application of Electronic Technique, 2019, 45(1): 14-18, 22.

## Research of personalized recommendation system based on deep neural network

Zi Yunfei, Li Yeli, Sun Huayan

(School of Information Engineering, Beijing Institute of Graphic Communication, Beijing 102600, China)

**Abstract:** The deep neural network is similar to the biological neural network, so it has the ability of high efficiency and accurate extraction of the deep hidden features of information, can learn multiple layers of abstract features, and can learn more about cross-domain, multi-source and heterogeneous content information. This paper presents an extraction feature based on multi-user-project combined deep neural network, self-learning and other advantages to achieve the model of personalized information. This model does deep neural network self-learning and extraction based on the input multi-source heterogeneous data characteristics, fuses collaborative filtering wide personalization to generate candidate sets, and then through two times of model self-learning produces a sort set. Finally, it can achieve accurate, real-time, and personalized recommendations. The experimental results show that the model can self-learn and extract the user's implicit feature well, and it can solve the problems of sparse and new items of traditional recommendation system to some extent, and realize more accurate, real-time and personalized recommendation.

**Key words:** deep neural network; personalized recommendation; candidate set; sort set; multi-view

### 0 引言

近几年,深度学习在人工智能、机器学习中取得了飞跃式的突破,特别是在语音识别和图像识别等领域<sup>[1-3]</sup>。其中,深度神经网络由于结构类似于生物神经网络,因此拥有高效、精准抽取信息深层隐含特征的能力和能够学习多层的抽象特征表示,且能够对跨域、多源、异质的内容信息进行学习等优势,可以一定程度上处理推荐系统稀疏性、新物品、可扩张性等问题,这为推荐系统解决固有问题带来了新的机遇。

本文提出了基于深度神经网络结合多用户-项目、协同过滤的推荐模型(Multi-View-Collaborative Filtering

integrating Deep Neural Network, MV-CFidNN)<sup>[4-6]</sup>,基于深度神经网络理论,提取用户、项目信息的深层隐含特征并自学习、优化提取模型,最后结合多用户-项目、协同过滤(Collaborative Filtering)提供广泛的个性化推荐。

### 1 深度神经网络推荐模型

基于深度学习的推荐系统通过将用户和项目的各类原始数据信息提供给输入层,在隐含层通过神经网络学习模型进行用户、项目的隐特征学习及抽取,最后通过学习隐表示实现用户、项目推荐<sup>[7-8]</sup>。基于深度神经网络框架的两次自学习并结合协同过滤的CFidNN框架如图1所示。CFidNN框架两大核心为:候选生成网络融合协同过滤与排名网络结合协同过滤。

\* 基金项目:北京市教委科技创新服务能力建设项目(04190117010)

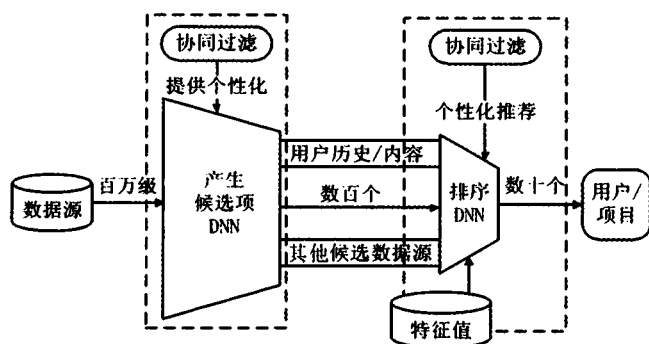


图1 CFiDNN 框架

其中,候选集产生以用户在浏览历史记录中的提取特征作为输入信息,然后基于多源数据库检索到与用户相关的一个数据集,这一数据集就是候选集。这部分候选集通过协同过滤(CF)实现广泛个性化。再通过用户、项目的多类特征源学习计算相似性,实现最小排名集,最后基于协同过滤实现推荐。

### 1.1 候选集生成模块

对于候选集生成,首先,将用户浏览及搜索项目等历史记录信息映射为向量,然后对其求平均值获取定长表示;并且,输入用户地理信息特征值优化个性化推荐效果,二值性和连续性特征值通过归一化得到[0,1]范围。其次,把所有输入特征值拼接到同一个向量,并且把拼接后的向量输入激活函数处理。最后,通过神经网络训练输给 Softmax 进行分类,通过训练的特征与源项目进行相似度计算,获取相似度最高的  $N$  个项目作为候选模块中的候选集,图2为候选生成结构图。

基于生成的候选集协同过滤提供广泛的个性化,组合基于用户-项目相关度评价实现精准、实时、个性化推荐。

候选集生成部分是基于多源异构数据库中学习选

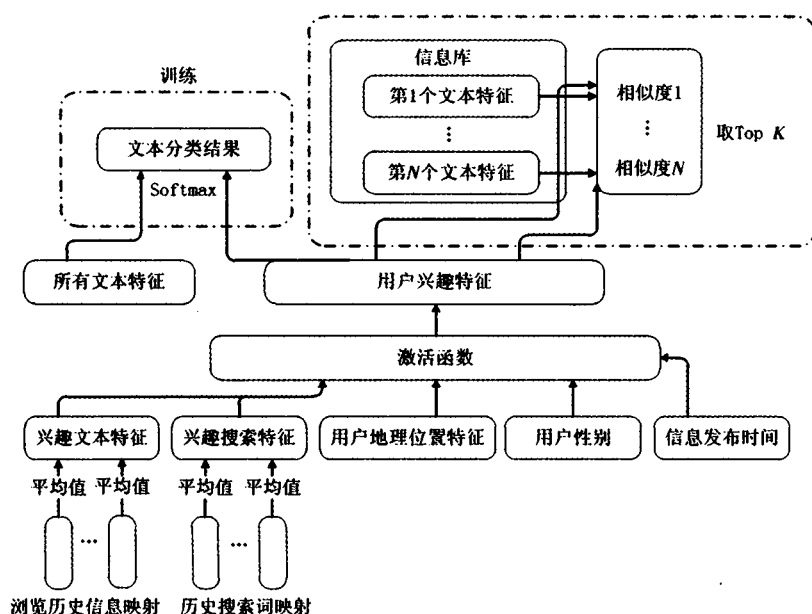


图2 CFiDNN 候选生成结构

择与用户相关度较高的项目,对于预测用户  $U$ ,其浏览某一个信息的概率为:

$$P(w_i=i|U, C) = \frac{e^{v_i \cdot u}}{\sum_{j \in V} e^{v_j \cdot u}} \quad (1)$$

其中,  $U$  是用户特征值,  $V$  表示多源异构数据库,  $v_i$  表示数据库中第  $i$  个项目的特征值,  $U$  与  $v_i$  向量拥有相等长度,它两通过点积在隐层全连接实现。

### 1.2 排序生成模块

排序生成结构与候选生成结构类似,区别在于排序生成是对候选生成集升级细致分类排序。与传统排序抽取特征值类似,神经网络排序也是通过拼接大量用户、项目相关特征值(文本 ID、浏览时长等)。特征值的处理与候选生成类似,都基于向量化,区别在于排序生成网络最后通过加权逻辑回归训练,给前期产生的候选集再评分,评分较高的  $K$  个项目返回给用户或通过协同过滤实现个性化推荐<sup>[8-10]</sup>。图3为排序生成结构图。

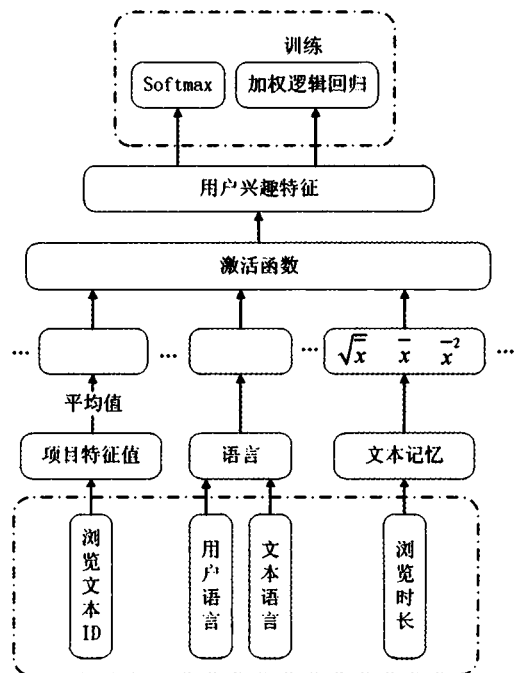


图3 CFiDNN 排序生成结构

设定部分 Softmax 分类过程:首先,对于候选生成集或排序生成列表的训练过程,通过对负样本类别采用实际类别计算将数量减小到数千;其次,在推荐阶段,不计 Softmax 归一化,将项目评分转化为点积空间的最近邻寻找或协同过滤根据相关度计算;最后,选取与用户  $U$  相关度最高的  $K$  项作为候选集或排序列表,然后通过协同过滤个性化推荐,把信息推荐给用户。

### 1.3 多用户-项目模型

基于多用户、多项目的多源异构特征结合

两次深度神经网络学习,从而实现个性化推荐。其实现思想为:首先,将原始特征值向量化后映射为用户、项目两个通道;然后利用深度神经网络模型把用户、项目信息向量映射到一个隐空间;最后,通过评估相似度(如余弦相似度法)把隐空间的用户、项目进行相关度等排名、匹配,从而实现精准、个性化推荐。图4为多用户-项目DNN(Deep Neural Network)模型结构<sup>[11-12]</sup>。

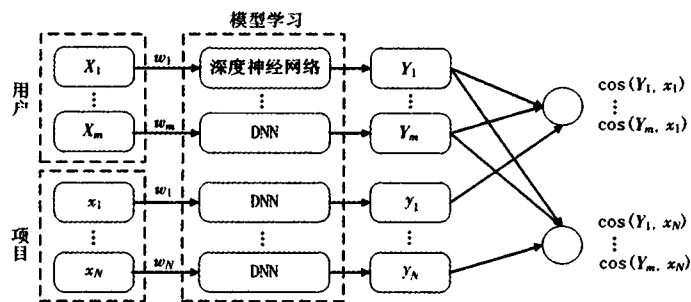


图4 多用户-项目 DNN 模型结构

在用户视角,利用其浏览历史、搜索(Search tokens)、位置信息、二值性(登录与否、性别)和连续性(年龄)、观看时长等作为源特征值输入 $x_u$ ,然后通过深度神经网络学习模型学习输出隐表示 $y_u$ 。在项目视角,利用项目的描述、标签、类型等作为源特征值输入 $x_i$ ,通过深度神经网络学习模型学习输出隐表示 $y_i$ ,其中模型拥有多个用户、项目,分别为 $m, N$ 。用户视角DNN模型为 $f_u(x_u, w_u)$ ,第 $i$ 个项目视角DNN模型为 $f_i(x_i, w_i)$ 。若拥有 $M$ 个样本 $\{(x_{u,j}, x_{a,j})\}, 0 \leq j \leq M, (x_{u,j}, x_{a,j})$ 是用户 $u$ 与项目 $a$ 的交互,利用用户、项目的拟合交互记录进行调参学习:

$$\arg \max_{w_u, w_i, \dots, w_a} \sum_{j=1}^M \frac{e^{\cos(f_u(x_{u,j}, w_u), f_i(x_{a,j}, w_a))}}{\sum_{1 \leq a \leq N} e^{\cos(f_u(x_{u,j}, w_u), f_i(x_{a,j}, w_a))}} \quad (2)$$

通过模型训练、学习之后获得的用户隐表示 $y_u$ 与项目隐表示 $y_i$ ,利用在隐空间中计算用户与项目的相关度、排名,选择相关度排序较高的 $k$ 项目以及源数据库协同过滤实现精准、个性化推荐。

#### 1.4 特征值向量化

特征值向量化是通过词组嵌入,将特制文本映射到 $w$ 维空间向量。首先,把用户、项目所有相关联特征值分别合并,并对特征值量化为评分数据然后求其平均值,即对多源异构原始数据进行评分式数据处理及归一化。

(1)用户特征数据为:

$$(\text{user}_i, c_{i0} \oplus c_{i1} \oplus \dots \oplus c_{in}, \frac{1}{n} \sum_{j=1}^n r_{ij}) \quad (3)$$

(2)项目特制数据为:

$$(\text{item}_j, c_{j0} \oplus c_{j1} \oplus \dots \oplus c_{jn}, \frac{1}{m} \sum_{i=1}^m r_{ij}) \quad (4)$$

其中, $\oplus$ 代表特制值空格连接符,整理得到:

$$(\text{user}_i, d_i^{\text{user}}, \bar{r}_i^{\text{user}}) \quad (5)$$

$$(\text{item}_j, d_j^{\text{item}}, \bar{r}_j^{\text{item}}) \quad (6)$$

其中, $d_i^{\text{user}}$ 是用户 $\text{user}_i$ 对项目 $\text{item}_1 \sim \text{item}_n$ 的评论, $d_j^{\text{item}}$ 为项目 $\text{item}_j$ 的评分, $\bar{r}_i^{\text{user}}$ 是用户 $\text{user}_i$ 对项目 $\text{item}_1 \sim \text{item}_n$ 的所有评分均值, $\bar{r}_j^{\text{item}}$ 为所有项目的评分均值。最后通过特征文本向量化技术,将所有用户、项目的评论数据进行向量化表示:

$$\text{vec}_i^{\text{user}} = \text{Doc2VecC}(d_i^{\text{user}}) \quad (7)$$

$$\text{vec}_j^{\text{item}} = \text{Doc2VecC}(d_j^{\text{item}}) \quad (8)$$

其中, $\text{vec}_i^{\text{user}}, \text{vec}_j^{\text{item}}$ 分别表示计算得到的第 $i$ 个用户、第 $j$ 个项目的特征值。Doc2VecC函数最后返回 $w$ 维向量,它是通过数据文档 $d_i^{\text{user}}$ 把词组嵌入获取平均值。同时,保证最后生成的向量在神经网络训练学习中能够自动抓取语义特征信息。通过特征值向量化后,用户 $i$ 特征值数据表示为:

$$(\text{user}_i, \text{vec}_i^{\text{user}}, \bar{r}_i^{\text{user}}) \quad (9)$$

项目 $j$ 特征值数据表示为:

$$(\text{item}_j, \text{vec}_j^{\text{item}}, \bar{r}_j^{\text{item}}) \quad (10)$$

#### 1.5 全连接层

全连接层(隐层)输入数据为用户、项目源特征值向量化后的值,设隐含层共 $m$ 个神经元,通过隐含层ReLU激活函数处理后,获得向量 $u_i$ ,就是用户 $\text{user}_i$ 隐特征值,同理,项目 $\text{item}_j$ 的隐特征值向量为 $v_j$ ,计算过程如下:

$$u_i = \text{ReLU}(w_{\text{user}_i} P_{\text{user}_i} + b_{\text{user}_i}) \quad (11)$$

$$v_j = \text{ReLU}(w_{\text{item}_j} P_{\text{item}_j} + b_{\text{item}_j}) \quad (12)$$

其中, $u_i, v_j \in R^m, w_{\text{user}_i}, w_{\text{item}_j}$ 分别表示用户、项目全连接层权值; $b_{\text{user}_i}, b_{\text{item}_j}$ 分别为对应偏置项,为实数; $P_t$ 为源特征值向量化输入后降维取最大项, $t \in [\text{user}_i, \text{item}_j]$ ;  $\text{ReLU}(x) = \max(0, x)$ 。

#### 1.6 矩阵分解

本文基于深度神经网络,分别构建候选网络模型融合协同过滤与排序网络模型结合协同过滤,利用用户浏览ID、Search tokens、用户地理信息、二值性等特征值,学习、抽取用户、项目隐含特征,分别为 $u_i, v_j$ 。然后通过用户、项目隐含特征内积,获得预测评分矩阵 $r'_{ij} \in R$ ,公式如下:

$$r'_{ij} = u_i \cdot v_j^T \quad (13)$$

最后,利用Adam深度学习优化方式对预测与真实评分进行拟合<sup>[13]</sup>,对于一些拥有评分的项目,使预测最大可能接近真实,由此学习推荐,对新物品实现个性化推荐(未评分项目预测真实评分无限接近预测值)。

$$r_{ij} \approx r'_{ij} = u_i \cdot v_j^T \quad (14)$$

## 2 实验仿真及分析

### 2.1 实验环境

算法性能分析的实验环境以 Windows Server2012 R2 操作系统为实验支撑,相关配置为: Intel® Xeon® Silver 4116 CPU 处理器, 编程语言 Python, 128 GB 内存, 双 GPU。编译环境在 Anaconda 的 Jupyter Notebook 中实现并采用 MATLAB 进行仿真。

### 2.2 数据集合

本文通过 2 个真实、实时数据集,对深度神经网络融合协同过滤推荐模型进行评估,数据集分别为 Amazon Movies and TV (AMT) 评论评分与 Amazon Clothing (AC) 视频评论、评分。数据包括用户 ID、物品 ID 及用户评论、评分。评分值为 1~5, 值越大用户喜好度越高。同时,实验数据按需求进行训练集 TrainSet 与测验集 TestSet 划分,且二者没有交集。

### 2.3 评价标准

本文提出的深度神经网络融合协同过滤推荐模型通过用户与项目的各类历史记录中抽取隐特征,然后对特征值进行学习预判、排序。因此本文应用均方根误差 (RMSE) 作为评价此模型的指标,通过学习特征模型与真实特征计算偏差,并求平方,然后与预测数据量  $N$  做比值平方根,计算公式如下:

$$RMSE = \sqrt{\frac{\sum_{i,j} (r_{ij} - \hat{r}_{ij})^2}{N}} \quad (15)$$

其中,  $r_{ij}$  为输入特征值向量化后的真实排名值,  $\hat{r}_{ij}$  为学习、训练之后的预测值,  $m$  为用户数量,  $n$  为项目数,  $N$  为测验集中的评分量。

### 2.4 实验对比

实验通过 3 个有效模型进行比较,分别为 Probabilistic Matrix Factorization (PMF)、LibMF 和 DNNMF。

### 2.5 执行时间对比分析

深度神经网络 (DNN) 推荐算法与传统协同过滤 (CF) 运行时间对比: 实验处理数据为 AMT、AC 真实数据,大小为 1.88 GB。深度神经网络输入节点为 1024 个,隐含层 18 个,输出节点 1024 个,Spark 集群节点为 3,比较深度神经网络训练与传统协同过滤处理数据集的耗时。实验结果如图 5 所示,其中 user 表示用户测试数据集耗时, item 表示商品测试数据集耗时。显然, DNN 执行效率更高。

### 2.6 实验结果与分析

实验在 2 个真实数据集下通过本文提出的 MV-CFi-DNN 模型进行计算评估,同时用 RMSE 来对模型进行评估预测,在相同实验环境与同一数据前提下,将 MV-CFi-DNN 与 PMF、LibMF 做比较分析。

参数设置为: 用户、项目特征值权重分别为  $\alpha=1, \beta=0.5$ , MV-CFiDNN 模型学习率为  $l_r=0.00065$ , 用户、项目




图 5 算法运行时间比较

隐特征正则化为  $\lambda_{user} = \lambda_{item} = \lambda$ , 深度神经网络神经元数为 1026 个。

为了将 MV-CFiDNN 模型与 PMF、LibMF 模型对比,把 2 个真实数据集随机分为 80% 的 TrainSet 与 20% 的 TestSet,且两者没有交集,同时把 TestSet 中的 20% 数据集随机用于验证,用来调整模型参数。

从图 6 可知,通过在 2 个真实数据集中测试后,PMF、LibMF 的 RMSE 值相差不大,但与 MV-CFiDNN 模型的 RMSE 值有一定差异,表明深度神经网络融合多用户-项目、协同过滤模型对于特征值抽取有很好效果。通过实验结果可以看出,本文提出的深度神经网络融合多用户-项目协同过滤模型 (MV-CFiDNN) 的 RMSE 值与 PMF、LibMF 模型比较,都有下降,说明 MV-CFiDNN 模型能够解决传统算法模型的稀疏性、新物品等问题。




图 6 仿真结果比较

## 3 结束语

本文通过深度神经网络融合协同过滤,提出了 MV-CFiDNN 模型,该模型首先对原数据库进行深度神经网络结合协同过滤个性化进行学习、提取特征值然后生成候选集,再对候选集进行二次学习、提取等生成排序集。产生候选集与排序集过程的深度神经网络学习方法包括输入层、隐含层及输出层,其中输入层是对输入特征

值进行向量化后与用户、项目权重内积传输给隐含层,隐含层根据接收到的值进行调参、重置等神经网络学习,然后学习、提取的特征值传递给输出层。通过计算得到预测值与真实值拟合。

未来研究可以通过多种神经网络结合更多基础推荐模型,以便使系统实现智能且符合人为思想的精准、个性化推荐。

#### 参考文献

- [1] PENG Y, ZHU W, ZHAO Y, et al. Cross-media analysis and reasoning: advances and directions[J]. Frontiers of Information Technology & Electronic Engineering, 2017, 18(1): 44-57.
- [2] COVINGTON P, ADAMS J, SARGIN E. Deep neural networks for youtube recommendations[C]. Proceedings of the 10th ACM Conference on Recommender Systems. ACM, 2016: 191-198.
- [3] LI P, WANG Z, REN Z, et al. Neural rating regression with

abstractive tips generation for recommendation[Z]. 2017.

- [4] SONG Y, ELKAHAY A M, HE X. Multi-rate deep learning for temporal recommendation[C]. Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2016: 909-912.
- [5] VASILE F, SMIRNOVA E, CONNEAU A. Meta-Prod2Vec: product embeddings using side-information for recommendation[C]. ACM Conference on Recommender Systems. ACM, 2016: 225-232.
- [6] HSIEH C K, YANG L, CUI Y, et al. Collaborative metric learning[C]. Proceedings of the 26th International Conference on World Wide Web. International World Wide Web Conferences Steering Committee, 2017: 193-201.
- [7] WANG X, HE X, NIE L, et al. Item silk road: recommending items from information domains to social users[Z]. 2017.
- [8] ROY S, GUNTUKU S C. Latent factor representations for

(下转第 22 页)

(上接第 13 页)

好地应用在 RGB-D SLAM 算法中。

#### 4 结论

本文在传统 ORB 算法的基础上,针对其存在特征点分布不均匀、重叠特征点较多的问题,提出一种改进 ORB 算法,并将该算法应用在移动机器人视觉导航中的 RGB-D SLAM 算法中。使用实验室自主研发的轮式移动机器人分别从图像特征点分布的均匀情况、特征点输出的重叠情况以及特征点提取与匹配消耗的时间情况三个方面比较传统 ORB 算法与改进 ORB 算法。实验结果表明,改进 ORB 算法特征点的分布较为均匀、输出特征点重叠数量较少、执行时间较短,可以更好地应用在 RGB-D SLAM 算法中。

#### 参考文献

- [1] KHAIRUDDIN A R, TALIB M S, HARON H. Review on simultaneous localization and mapping(SLAM)[C]. IEEE International Conference on Control System, Computing and Engineering. IEEE, 2016: 85-90.
- [2] 党宏社, 候金良, 强华, 等. 基于视觉引导的 SCARA 机器人自动装配系统[J]. 电子技术应用, 2017, 43(5): 21-24.
- [3] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [4] BAY H, ESS A, TUYTELAARS T, et al. Speeded-up robust features(SURF)[J]. Computer Vision & Image Understanding, 2008, 110(3): 346-359.
- [5] RUBLEE E, RABAU D V, KONOLIGE K, et al. ORB: an

efficient alternative to SIFT or SURF[C]. International Conference on Computer Vision. IEEE, 2012: 2564-2571.

- [6] 刘宏伟, 余辉亮, 梁艳阳. ORB 特征四叉树均匀分布算法[J]. 自动化仪表, 2018, 39(5): 52-54, 59.
- [7] 毛星云. OpenCV3 编程入门[M]. 北京: 电子工业出版社, 2015.
- [8] XU J, CHANG H W, YANG S, et al. Fast feature-based video stabilization without accumulative global motion estimation[J]. IEEE Transactions on Consumer Electronics, 2012, 58(3): 993-999.
- [9] PRIVITERA C M, STARK L W. Algorithms for defining visual regions-of-interest: comparison with eye fixations[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2000, 22(9): 970-982.
- [10] HOSANG J, BENENSON R, SCHIELE B. A convnet for non-maximum suppression[M]. Pattern Recognition. Springer International Publishing, 2016: 192-204.
- [11] KEI O. ROS(robot operating system)[J]. Journal of the Robotics Society of Japan, 2012, 30(9): 830-835.
- [12] 宋艳. 基于图像特征的 RGB-D 视觉 SLAM 算法[D]. 青岛: 中国海洋大学, 2015.

(收稿日期: 2018-11-11)

#### 作者简介:

成怡(1979-), 女, 博士, 副教授, 主要研究方向: 机器人被动导航。

佟晓宇(1993-), 女, 硕士研究生, 主要研究方向: 视觉 SLAM、图像处理。




图8  $S_{11}$  和  $S_{23}$




图9  $S_{21}$  和  $S_{31}$

三端口网络的S参数,通过CAD软件进行仿真验证并优化设计。理论分析结果与仿真数据基本吻合,验证了理论的正确与设计的可行性。

#### 参考文献

- [1] POZAR D M. Microwave engineering (3rd ed) [M]. New York: Wiley Press, 2005.
- [2] 范海军,周希朗.新型小型化超宽带功率分配器的设计[J].电子技术应用,2011,34(23):20-22,26.
- [3] PARK M J. Dual-band unequal power divider with simplified structure [J]. IET Microwaves Antennas & Propagation, 2011, 5(15): 1891-1896.
- [4] YANG I, KAHNG S, KAHNG K S, et al. Dual-band unequal power divider miniaturized by fully printed CRLH phase shift lines [C]. Proceedings of the 43rd European Microwave Conference, 2013: 140-143.

- [5] ROBERT E C. Foundations for microwave engineering (2nd ed) [M]. New York: Wiley Press, 2001: 394-480.
- [6] LIN I H, VINCENTIS M D, CALOZ C, et al. Arbitrary dual-band components using composite right/left-hand transmission lines [J]. IEEE Transactions on Microwave Theory and Techniques, 2004, 52(4): 1142-1149.

(收稿日期:2018-05-08)

#### 作者简介:

林剑欣(1990-),男,硕士研究生,主要研究方向:射频、微波及毫米波单片集成电路及组件等。

余凯(1983-),通信作者,男,博士,副教授,主要研究方向:射频及模拟集成电路设计,E-mail:k.yu@gdut.edu.cn。

李思臻(1983-),女,博士,讲师,主要研究方向:射频及模拟集成电路设计。

(上接第18页)

- cold-start video recommendation [C]. Proceedings of the 10th ACM Conference on Recommender Systems. ACM, 2016: 99-106.
- [9] ZHENG L, NOROOZI V, YU P S. Joint deep modeling of users and items using reviews for recommendation [C]. Proceedings of the Tenth ACM International Conference on Web Search and Data Mining. ACM, 2017: 425-434.
- [10] EBESU T, FANG Y. Neural citation network for context-aware citation recommendation [C]. International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2017: 1093-1096.
- [11] Zhang Qi, Wang Jiawen, Huang Haoran, et al. Hashtag recommendation for multimodal microblog using co-attention network [C]. IJCAI2017, 2017.

- [12] WEI J, HE J, CHEN K, et al. Collaborative filtering and deep learning based recommendation system for cold start items [J]. Expert Systems with Applications, 2017, 69: 29-39.
- [13] WANG S, WANG Y, TANG J, et al. What your images reveal: exploiting visual contents for point-of-interest recommendation [C]. Proceedings of the 26th International Conference on World Wide Web. International World Wide Web Conferences Steering Committee, 2017: 391-400.

(收稿日期:2018-05-13)

#### 作者信息:

字云飞(1991-),通信作者,男,硕士研究生,主要研究方向:数据挖掘、推荐算法、深度学习及可视化分析,E-mail:527260533@qq.com。

李业丽(1962-),女,教授,主要研究方向:大数据、数据挖掘。